

AR-GE RAPORU: CPU Üzerinde Duygu Analizi Optimizasyonu

Hazırlayan: Kerem Keskinoglu

Proje: CallMetricsAI

Tarih: 21 Nisan 2026

1. Giriş ve Görev Tanımı

Bu rapor, ses (Wav2Vec 2.0) ve metin (BERT) duygu analizi modellerinin donanım maliyetlerini minimize ederek, GPU yatırımı gerektirmeden CPU üzerinde anlık (real-time) çıkarım performanslarını analiz etmek amacıyla hazırlanmıştır. Çalışmada vLLM motorunun uyumluluğu ve ONNX Runtime optimizasyonlarının etkileri incelenmiştir.

2. vLLM Uyumluluk Değerlendirmesi

vLLM motorunun mimarisi, "Decoder-only" (üretken) modellerin (Llama, Qwen vb.) token üretim süreçlerini hızlandırmak için tasarlanmıştır. Projemizde kullanılan modellerin karakteristikleri şöyledir:

- BERT (savasy/bert-base-turkish-sentiment-cased):** Bir "Encoder-only" sınıflandırma modelidir. vLLM tarafından desteklenmemektedir.
- Wav2Vec 2.0 (superb/wav2vec2-base-superb-er):** Ses dalgalarını işleyen bir akustik modeldir ve vLLM mimarisine uygun değildir.

Sonuç: Bu modellerin servis edilmesi için vLLM yerine ONNX Runtime tabanlı bir mikroservis mimarisi tercih edilmiştir.

3. Performans ve Gecikme (Latency) Analizi

Testler, 8 fiziksel / 12 mantıksal çekirdekli Intel CPU ve 16 GB RAM içeren Windows 11 ortamında gerçekleştirilmiştir.

3.1. BERT (Metin Duygu Analizi) Sonuçları

Mimarî Yapı	Ortalama Gecikme (Latency)	Performans Durumu
Saf PyTorch (Optimize Edilmemiş)	88.61 ms	Başarılı (< 100ms)
ONNX Runtime (Optimize Edilmiş)	18.11 ms	Mükemmel (5x Hız Artışı)

3.2. Wav2Vec 2.0 (Ses Duygu Analizi) Sonuçları

Ses modellerinde performans RTF (Real-Time Factor) metriği ile ölçülmüştür. RTF < 1.0 değeri gerçek zamanlı işleme kapasitesini gösterir.

- **3 Saniyelik Ses:** 0.17 sn işlem süresi (RTF: 0.058)
- **5 Saniyelik Ses:** 0.27 sn işlem süresi (RTF: 0.054)
- **10 Saniyelik Ses:** 0.60 sn işlem süresi (RTF: 0.060)

Bulgu: Sistem, ses verisini gerçek zamandan yaklaşık 17 kat daha hızlı işleyebilmektedir.

4. Model Mantık Bulguları ve Kalite Kontrol

Testler sırasında modelin Türkçe deyimleri ve çift negatifi ("fena değil" gibi) yanlış sınıflandırdığı tespit edilmiştir. Bu durum, modelin ikili (binary) sınıflama yapmasından kaynaklanmaktadır. Prodüksiyon aşamasında modelin şirket verileriyle *fine-tune* edilmesi kritik önem taşımaktadır.

5. Nihai Sonuç ve Tavsiye

Yapılan Ar-Ge çalışmaları sonucunda, GPU yatırımı yapılmasına gerek olmadığı bilimsel verilerle kanıtlanmıştır. ONNX optimizasyonu ile CPU üzerinde 18ms gecikme sürelerine inilebilmekte, bu da maliyetleri sıfıra indirirken performansı maksimize etmektedir.

6. İlgili Görseller

```
[*] ONNX Modeli CPU üzerinde başlatılıyor...
Device set to use cpu
[+] ONNX Modeli başarıyla yüklendi.

Metin: Müşteri temsilcisi sorunumu saniyeler içinde çözdü, gerçekten harika bir hizmet
!
Sonuç: positive | Skor: 0.9887
ONNX Gecikmesi: 18.11 ms
```

[+] Model Başarıyla Yüklendi.

[*] CPU Isınma Turu Başlatılıyor...

[+] Isınma Tamamlandı.

WAV2VEC 2.0 CPU BENCHMARK TESTİ (RTF Ölçümü)

Ses Uzunluğu : 3 saniye
İşleme Süresi: 0.17 saniye
Çıkan Duygu : hap
RTF Değeri : 0.058 (BAŞARILI - Anlık/Real-Time çalışıyor!)

Ses Uzunluğu : 5 saniye
İşleme Süresi: 0.27 saniye
Çıkan Duygu : ang
RTF Değeri : 0.054 (BAŞARILI - Anlık/Real-Time çalışıyor!)

Ses Uzunluğu : 10 saniye
İşleme Süresi: 0.60 saniye
Çıkan Duygu : ang
RTF Değeri : 0.060 (BAŞARILI - Anlık/Real-Time çalışıyor!)

[+] Model başarıyla yüklendi.

SİSTEM DONANIM BİLGİLERİ

İşletim Sistemi : Windows 11
İşlemci (CPU) : Intel64 Family 6 Model 154 Stepping 3, GenuineIntel
Fiziksel Çekirdek: 8
Mantıksal Çekirdek: 12
Toplam RAM : 16 GB

[*] CPU ısınma turu başlatılıyor...

[+] Isınma tamamlandı.

BENCHMARK TESTİ BAŞLIYOR (Batch Size = 1)

- Metin: 'Uygulamayı kullanırken çok zorlandım, sürekli hata veriyor ve ekran donuyor.'
Duygu: negative | Skor: 0.9996 | Gecikme: 70.86 ms
- Metin: 'Bugün hava fena değil, işe yürüyerek gitmeye karar verdim.'
Duygu: negative | Skor: 0.9601 | Gecikme: 65.23 ms
- Metin: 'Müşteri temsilcisi sorunumu saniyeler içinde çözdü, gerçekten harika bir hizmet!'
Duygu: positive | Skor: 0.9887 | Gecikme: 76.31 ms
- Metin: 'Dün verdiğim sipariş henüz kargoya verilmemiş, bilgi alabilir miyim?'
Duygu: negative | Skor: 0.9790 | Gecikme: 145.21 ms
- Metin: 'Hayatımda gördüğüm en muazzam tasarımlardan birini yapmışsınız, tebrikler.'
Duygu: positive | Skor: 0.9954 | Gecikme: 85.45 ms

[!] Ortalama Gecikme (Average Latency): 88.61 ms